

DOCUMENTAÇÃO DO CÓDIGO

Organização do Projeto:

C:\project

```
└─ healdb
  └─ data
    └─ input
      └─ bulas
        └─ categorias
          └─ biologico
          └─ dinamizado
          └─ especifico
          └─ fitoterapico
          └─ generico
          └─ novo
          └─ prod_tp
          └─ radiofarmaco
          └─ similar
        └─ Arquivo_sintomas.csv
        └─ CID-10-CAPITULOS.csv
        └─ CID-10-CATEGORIAS.csv
        └─ CID-10-GRUPOS.csv
        └─ CID-10-SUBCATEGORIAS.csv
        └─ consulta_medicamento_anvisa.csv
        └─ DADOS_ABERTOS_MEDICAMENTOS.csv
        └─ drugbank_file.xml
        └─ input_active_ing_translate_meta
        └─ lista_dcb.xlsx
        └─ ddls
          └─ healdb_hd_active_ingredient.sql
          └─ healdb_hd_active_ingredient_ext_id.sql
          └─ healdb_hd_company.sql
          └─ healdb_hd_drug_interaction.sql
          └─ healdb_hd_icd_category.sql
          └─ healdb_hd_icd_group.sql
          └─ healdb_hd_icd_subcategory.sql
          └─ healdb_hd_medication.sql
          └─ healdb_hd_medication_active_ingredient.sql
          └─ healdb_hd_medication_disease.sql
          └─ healdb_hd_medication_drug_leaflet.sql
          └─ healdb_hd_regulatory_category.sql
          └─ healdb_hd_symptom.sql
          └─ healdb_hd_therapeutic_class.sql
          └─ healdb_hd_type_ext_id.sql
```

- | | | └─ ddl_summary.xlsx
- | | └─ icd_eng
 - | | └─ blocks.txt
 - | | └─ categories.txt
 - | | └─ chapters.txt
- | | └─ ontologies
 - | | └─ ATC.ttl # RDF Schema ATC
 - | | └─ chebi.owl # RDF Schema CHEBI
 - | | └─ healdb_mini.owl # RDF Schema subset HealDB
 - | | └─ pc_cooccurrence_chemical_and_disease_000001.ttl # RDF Schema PUBCHEM
- Chemical
 - | | └─ pc_cooccurrence_chemical_and_disease_000002.ttl # RDF Schema PUBCHEM
- Chemical
 - | | └─ pc_cooccurrence_chemical_and_disease_000003.ttl # RDF Schema PUBCHEM
- Chemical
 - | | └─ pc_disease.ttl # RDF Schema PUBCHEM Diseases
 - | └─ output
 - | └─ downloadBulas
 - | └─ translation
 - | └─ output_active_ing_translate_meta.csv
 - | └─ interoperability
 - | └─ _attempts
 - | └─ iucn_conservation_dcb_r.json
 - | └─ iucn_conservation_healdb_r.json
 - | └─ pubchem_diseases_labels.csv
 - | └─ pubchem_mesh_disease_healdb.csv
 - | └─ pubchem_mesh_ids_healdb.csv
 - | └─ atc
 - | └─ atc_attributes_healdb.csv
 - | └─ atc_attributes_theraphealdb.csv
 - | └─ chebi
 - | └─ chebi_attributes_healdb.csv
 - | └─ chebi_attributes_healdb_json.json
 - | └─ clinical_trials
 - | └─ clinical_trials_healdb.csv
 - | └─ clinical_trials_healdb.json
 - | └─ iucn
 - | └─ iucn_conservation_dcb.json
 - | └─ iucn_conservation_healdb.json
 - | └─ pubchem
 - | └─ pubchem_reference_healdb.json
 - | └─ rxnorm
 - | └─ rxnorm_enrichment_healdb.json
 - | └─ rdf_schema

```

| | | |─ healdb_complete.ttl
| | | |─ healdb_mini.ttl
|
|─ doc
|─ logs
|─ notebooks
| |─ exploracao_healdb_completa.ypynb # Notebook para exploração da base HealDB
| |─ exploracao_healdb_completa.html # Visualização da exploração da base HealDB
|─ src
| |─ rdf_schema
| | |─ __init__.py
| | |─ main_rdf_schema.py
| | |─ create_healdb_rdf_schema.py # Complete RDF schema for HealDB
| | |─ create_mini_healdb_rdf_schema.py # Mini RDF schema with instance data
|
| |─ interoperability
| | |─ __init__.py
| | |─ main_interoperability.py
| | |─ linking
| | | |─ __init__.py
| | | |─ external_ids_insert.py
| | | |─ fill_missing_external_ids.py
| | | |─ import_dcb_data.py
| | | |─ link_cas_to_active_ing.py
| | | |─ link_drugbank_to_active_ing.py
| | | |─ link_kegg_related_ids_to_active_ing.py
| | | |─ link_rxcui_related_ids_to_active_ing.py
| | | |─ link_rxcui_to_active_ing.py
| | | |─ link_wikidata_ids_to_wrk_table.py
| | | |─ populate_external_ids_types.py
| | |─ usecases
| | | |─ __init__.py
| | | |─ _attempts
| | | | |─ iiucn_export_conservation_status_r.r
| | | |─ pubchem_disease_mesh_query.txt # SPARQL query for PubChem Disease
|
Mesh
| | | |─ pubchem_disease_query.txt # SPARQL query for PUBchem Disease
| | | |─ pubchem_mesh_ids_query.txt # SPARQL query for PUBChem Mesh
| | | |─ atc_attributes_query.txt # SPARQL query for ATC
| | | |─ atc_attributes_theraphealdb_query.txt # SPARQL query for ATC
| | | |─ chebi_attributes_query.txt # SPARQL query for CHEBI
| | | |─ clinical_trials_export.py # SPARQL query for ClinicalTrials.gov
| | | |─ iucn_export_conservation_status.py # IUCN integration
| | | |─ pubchem_export_references.py # PubChem integration

```

```

| | | └─ rxnorm_export_enriched_ingredients.py # RxNorm integration
|
| └─ nlp_extraction
| | └─ __init__.py
| | └─ main_nlp_extraction.py
| | └─ extract_leaflet_sections.py
| | └─ extract_diseases_from_indications.py
| | └─ link_medications_with_diseases.py
| | └─ process_disease_data_json.py
| | └─ translate_leaflet_section.py
|
| └─ repositories
| | └─ __init__.py
| | └─ main_repository.py
| | └─ create_activeingr_repository.py
| | └─ create_diseases_repository.py
| | └─ create_drugbank_repository.py
| | └─ create_leaflets_repository.py
| | └─ create_medications_repository.py
| | └─ create_symptoms_repository.py
| | └─ drugbank_inserts.py
|
| └─ translation
| | └─ __init__.py
| | └─ main_translation.py
| | └─ import_translated_active_ingredients_meta.py
| | └─ import_translated_active_ingredients_meta.py
| | └─ translate_active_ingredients.py
| | └─ translate_active_ingredients_meta.ipynb
| | └─ translate_disease_descriptions.py
| | └─ translate_drug_interactions.py
| | └─ translate_food_interactions.py
| | └─ validate_translation_and_link_active_ing.py
|
| └─ webcrawler
| | └─ __init__.py
| | └─ main_webcrawler.py
| | └─ webcrawler_leaflet.py
└─ tests
└─ requirements.txt
└─ config.py
└─ db_utils.py
└─ main.py

```

1. Pasta: c:\project\healdb\src\webcrawler

WEBCRAWLER_LEAFLET:

Objetivo: Automatizar a coleta e o armazenamento das bulas do Bulário Eletrônico da ANVISA, utilizando web crawling e web scraping para todas as categorias de bula.

Processo:

1. Automatização da navegação:
 - a) Utilizar a biblioteca **Selenium** para automatizar a navegação no Bulário Eletrônico da ANVISA, selecionando cada uma das 9 categorias de bula e acionando o botão de consulta correspondente.
2. Coleta de Dados:
 - a) Armazenar o conteúdo da tabela com os dados dos medicamentos em um DataFrame.
 - b) Percorrer todas as páginas dentro de cada categoria de bula.
 - c) Utilizar a biblioteca **BeautifulSoup** para realizar o web scraping da tabela contendo os dados das bulas em cada página.
3. Download e Armazenamento das Bulas:
 - a) Para cada URL de bula obtida (usando o driver do Selenium), realizar o download automático do arquivo da bula, que será salvo na pasta específica da categoria correspondente.
 - b) Atualizar o DataFrame com o nome do arquivo da bula e seu caminho (path) em PDF.
4. Registro e Arquivamento:
 - a) Após o processamento de todas as páginas de uma categoria, armazenar os dados do DataFrame em um arquivo Excel na respectiva pasta de categoria. Este arquivo Excel incluirá uma coluna com o caminho do arquivo PDF da bula.
5. Integração Posterior:
 - a) O arquivo Excel gerado será utilizado posteriormente pelo script `create_leaflets_repository.py` para integrar as bulas à base de dados.

Este processo assegura a coleta e organização sistemática das bulas, facilitando a integração e análise dos dados na base HealDB.

2. Pasta: c:\project\healdb\src\repositories

CREATE_MEDICATIONS_REPOSITORY:

Objetivo: Criar o repositórios de medicamentos.

Processo:

1. Utilizar fontes de dados externas: DADOS_ABERTOS_MEDICAMENTOS em formato csv do DataVisa.
2. Armazenar os dados nas seguinte tabelas do MySQL:
 - a) `hd_medication`: Armazenar informações sobre medicamentos.
 - b) `hd_therapeutic_class`: Armazenar as classes terapêuticas.
 - c) `hd_regulatory_category`: Armazenar as categorias regulatórias dos medicamentos.
3. Processar os medicamentos:
 - a) Extrair as classes terapêuticas e armazenar na respectiva tabela.
 - b) Extrair as categorias regulatórias e armazenar na respectiva tabela.
 - c) Armazenar os medicamentos e ligá-los com a classe terapêutica e categoria regulatória.

CREATE_DISEASES_REPOSITORY:

Objetivo: Criar o repositório de doenças.

Processo:

1. Utilizar fontes de dados externas: CID-10 em formato CSV.
2. Armazenar os dados nas seguintes tabelas do MySQL:
 - a) `hd_icd_group`: Armazenar dados sobre grupos de doenças do CID.
 - b) `hd_icd_category`: Armazenar dados sobre as categorias de doenças do CID.
 - c) `hd_icd_subcategory`: Armazenar dados sobre as subcategorias de doenças do CID.
3. Processar as doenças e inseri-las nas tabelas.

CREATE_SYMPTOMS_REPOSITORY:

Objetivo: Criar o repositório de sintomas usando dados hierárquicos do vocabulário controlado do BIREME/MeSH.

Processo:

1. Utilizar fontes de dados externas: BIREME/MeSH (vocabulário controlado de termos biomédicos que serve para indexar documentos e recuperar informações científicas) para os sintomas em formato csv.
2. Armazenar os dados na seguinte tabela do MySQL:
 - a) `hd_symptom`: Armazenar dados de sintomas.
3. Processar os sintomas e inseri-los de forma hierárquica na tabela.

CREATE_ACTIVEINGR_REPOSITORY:

Objetivo: Criar o repositório de princípios ativos.

Processo:

1. Ler os princípios ativos dos medicamentos armazenados na tabela `hd_medication`.
2. Armazenas os dados nas seguintes tabelas do MySQL:
 - a) `hd_active_ingredient`: Armazenar os dados de princípios ativos.
 - b) `hd_medication_active_ingredient`: Armazenar o relacionamento entre medicamentos e princípios ativos.
3. Processar os princípios ativos dos medicamentos:
 - a) Dividir os princípios ativos no campo de princípio ativo da tabela usando o separador "+".
 - b) Armazenar o resultado na tabela de trabalho `hd_wrk_medication_active_ing`, associando cada medicamento aos seus princípios ativos normalizados.
 - c) A partir desta tabela de trabalho, armazenar os princípios ativos no repositório `hd_active_ingredient`.
 - d) Estabelecer a correlação entre medicamentos e seus princípios ativos (usando o ID criado na tabela `active_ingredient`) e armazenar essa relação na tabela `medication_active_ingredient`.

CREATE_LEAFLETS_REPOSITORY:

Objetivo: Ler as pastas contendo as bulas baixadas do site da ANVISA em PDF, organizadas por categorias (biológico, dinamizado, específico, fitoterápico, genérico, novo, produto de terapia, radiofármaco e similar), e armazenar essas bulas na tabela `hd_medication_drug_leaflet` da base de dados MySQL.

Processo:

1. Para cada categoria de bula, ler o arquivo Excel com a lista de bulas.
2. Armazenar o conteúdo do arquivo Excel na tabela de trabalho `hd_wrk_drug_leaflet`.
3. Realizar a deduplicação das bulas, removendo as versões mais antigas e armazenando os dados na tabela de trabalho `hd_wrk_drug_leaflet_dedup`.
4. Carregar todos os registros da tabela `hd_wrk_drug_leaflet_dedup` em um DataFrame.
5. Para cada registro do DataFrame, ler o arquivo PDF da bula usando a biblioteca **PyMuPDF** (módulo **Fitz**). PyMuPDF é uma biblioteca Python de alto desempenho para extração, análise, conversão e manipulação de documentos PDF (e outros).
6. Para bulas no formato de imagem, utilizar a biblioteca **Pytesseract** para realizar a extração de texto. Python-tesseract é uma ferramenta de reconhecimento óptico de caracteres (OCR) para Python. Ou seja, ela reconhece e 'lê' o texto embutido em imagens.
7. Armazenar o conteúdo extraído no DataFrame e salvar na tabela `hd_medication_drug_leaflet`, incluindo o texto das bulas.
8. Realizar uma revisão adicional das bulas identificadas manualmente como imagens e tentar extrair o texto usando Pytesseract, se necessário.

CREATE_DRUGBANK_REPOSITORY:

Objetivo: Criar um repositório para os dados do DrugBank disponibilizados em um arquivo XML. Esses dados incluem informações sobre as drogas catalogadas no DrugBank, sinônimos, ingredientes do produto (formas salinas da droga), interações medicamentosas, interações entre

drogas e alimentos. Os atributos coletadas das drogas são: identificador no DrugBank, nome, descrição e indicação do uso da droga.

Processo:

1. Ler o arquivo XML do DrugBank.
2. Selecionar as tags: `drugname-id`, `name`, `description`, `indication`, `food-interaction`, `drug-interaction`, `synonym`, `salt`, `external-id`.
3. Armazenar em um DataFrame.
4. Criar o repositório do DrugBank chamando o script `drugbank_inserts.py` para inserir as informações que se encontram no DataFrame nas tabelas que compõem o repositório.

DRUGBANK_INSERTS:

Objetivo: Criar um repositório para os dados do DrugBank disponibilizados em um arquivo XML. Esses dados incluem informações sobre as drogas catalogadas no DrugBank, sinônimos, ingredientes do produto (formas salinas da droga), interações medicamentosas, interações entre drogas e alimentos. Os atributos coletadas das drogas são: identificador no DrugBank, nome, descrição e indicação do uso da droga.

Processo:

1. Inserir as informações das drogas na tabela `db_drug`.
2. Inserir as interações das drogas com alimentos na tabela `db_food_interaction`.
3. Inserir os sinônimos das drogas na tabela `db_synonym`.
4. Inserir as informações das formas salinas das drogas na tabela `db_product_ingredient`.
5. Inserir as informações dos ids externos que permitem interoperabilidade do drugbank com outras fontes de dados de saúde na tabela `db_drug_external_id`.
6. Inserir as informações das interações medicamentosas na tabela `db_drug_interaction`.
 - a. Pesquisar o ID da droga com a qual a droga principal interage, utilizando o `id_DrugBank`, que é um identificador imutável registrado no DrugBank.
 - b. Efetuar a inserção de todas as informações na tabela `db_drug_interaction` em modo batch, com o batch size igual a 2000 (inserção a cada 2000 registros).

3. Pasta: c:\project\healdb\src\translation

TRANSLATE_ACTIVE_INGREDIENTS:

Objetivo: Traduzir os princípios ativos para o inglês usando a API do OPENAI. Atualmente, utilizamos o modelo `gpt-4-0314`.

Obs: Os dois modelos `gpt-4-0314` e `gpt-3.5-turbo-1106` retornam o mesmo resultado. Caso seja necessário repetir o processo, recomenda-se o uso do `gpt-3.5-turbo-1106`, por ser mais leve e econômico.

Processo:

1. Copiar o conteúdo da tabela `hd_active_ingredient` para a tabela `hd_translate_eng_active_ing`, que armazenará as traduções dos princípios ativos.
2. Configurar as variáveis da API do OpenAI.
3. Ler os princípios ativos da tabela `hd_translate_eng_active_ing`.
4. Para cada princípio ativo, chamar a API do OpenAI utilizando o modelo `gpt-4-0314`.
5. Armazenar as traduções em um DataFrame.
6. Atualizar a tabela `hd_translate_eng_active_ing` com o princípio ativo traduzido para o inglês no campo `nm_active_ingredient_eng_ini`.
7. Além da tradução inicial, a tabela possui dois outros campos: um para revisão manual, se necessário (`review`), e outro para a tradução final (`eng`), que combina a tradução inicial com a revisão.

VALIDATE_TRANSLATION_AND_LINK_ACTIVE_ING:

Objetivo: Validar a tradução dos princípios ativos de duas formas:

- Verificar a correspondência do termo traduzido automaticamente (GPT-4.0) nas tabelas do DrugBank relacionadas a drogas, sinônimos e ingredientes dos produtos.
- Confirmar a correspondência do termo traduzido manualmente nas mesmas tabelas.

Processo:

1. Validar o termo traduzido automaticamente pela API da OpenAI (modelo `gpt-4-0314`) contra os dados do DrugBank.
2. Buscar o termo traduzido nas tabelas de drogas, sinônimos e ingredientes dos produtos, identificando os IDs correspondentes (`id_drug` e `id_DrugBank`).
3. Validar o termo traduzido manualmente contra os dados do DrugBank.
4. Armazenar a tradução final: usar a tradução manual se existir; caso contrário usar a tradução automática.
5. Inserir na tabela de princípios ativos X drogas (`hd_priv_active_ingredient_drug`) a relação entre o princípio ativo (em português) e a droga do DrugBank (em inglês).

OBS: essa relação entre o princípio ativo e a droga será utilizada para capturar as interações medicamentosas relacionadas com esse princípio ativo.

TRANSLATE_ACTIVE_INGREDIENTS_META:

Objetivo: Traduzir os princípios ativos para o inglês usando o modelo `SeamlessMT4` do META. Este script foi desenvolvido no google colab (notebook).

Processo:

1. Exportar o conteúdo da tabela `hd_active_ingredient` para um arquivo CSV.
2. Ler o arquivo CSV e armazenar em um DataFrame.
3. Efetuar a tradução usando o modelo `SeamlessMT4`.
4. Armazenar a tradução em um DataFrame.
5. Exportar o DataFrame com a tradução para um arquivo CSV.

IMPORT_TRANSLATED_ACTIVE_INGREDIENTS_META:

Objetivo: Importar a tradução do princípio ativo feita pelo modelo do META para comparar posteriormente com os dados do DrugBank.

Processo:

1. Importar o arquivo CSV contendo a tradução dos princípios ativos para a tabela `hd_wrk_translate_eng_active_ing_meta`.
2. Validar a tradução comparando o conteúdo da tabela `hd_wrk_translate_eng_active_ing_meta` com os medicamentos do DrugBank.
3. Computar o total de correspondências com o DrugBank.

OBS: O modelo GPT-4 conseguiu corresponder a 1.436 ingredientes ativos (60% do total) do repositório DrugBank, enquanto o modelo SeamlessM4T obteve apenas 143 correspondências (6% do total). Devido ao desempenho insatisfatório do modelo META, que apresentou erros significativos de tradução (por exemplo, traduzir "Insulina Glulisina" como "insuline and glutamine" ou "Óxido cúprico" como "Oxygenated copper"), decidiu-se utilizar o modelo GPT-4.0. As traduções foram validadas com base na correspondência correta encontrada no DrugBank. Por exemplo, embora as traduções "sulfate of sodium" e "sodium sulfate" estejam corretas, "sodium sulfate" foi considerada a forma correta com base no DrugBank.

TRANSLATE_FOOD_INTERACTIONS:

Objetivo: Traduzir as interações de alimentos do DrugBank do inglês para o português usando a API da OpenAI (modelo GPT-3.5) e enriquecer a base HealDB com essas informações.

Processo:

1. Inserir as interações de alimentos do DrugBank (`db_food_interaction`) na tabela de tradução (`hd_priv_translate_port_food_int`) cruzando com os princípios ativos existentes na base HealDB.
 - a. Ao inserir na tabela de tradução, substituir o nome da droga associada à interação por uma variável XXX (para possibilitar posteriormente a substituição dessa variável pelo princípio ativo em português já existente na base HealDB).
2. Enriquecer a base HealDB com as interações traduzidas.
 - a. Traduzir o campo que contém as interações com a variável XXX (`ds_interaction_var`) usando a API do OpenAI (modelo GPT-3.5). Traduzir as interações distintas, já que algumas se repetem devido ao uso da variável para o nome da droga, o que reduz o tempo de tradução. Foi escolhido o modelo GPT-3.5 porque o GPT-4.0 estava muito lento e a qualidade da tradução foi similar. Armazenar a informação traduzida em uma coluna da tabela, ainda com a variável XXX (`ds_interaction_var_port`). (Funções: `perform_food_interaction_translation` e `update_translate_food_interaction`).
 - b. Substituir a variável XXX pelo princípio ativo em português da base HealDB e salvar na tabela final que compõe a base de medicamentos, na tabela `hd_priv_food_interaction`. (Funções: `replace_var_by_active_ingredient` e `insert_food_interaction`)

Resultado: A base HealDB será enriquecida com as interações de alimentos:

- **A quantidade de interações resultantes foi 1.781.** Existem algumas interações repetidas, porque alguns princípios ativos são similares e se referem a mesma droga. Isso ocorre porque não foi feita a desambiguação dos princípios ativos, resultando em entradas duplicadas com descrições diferentes. No entanto, isso não compromete o resultado final de busca da interação a partir do MEDICAMENTO X PRINCÍPIO ATIVO. Se a desambiguação fosse realizada, a quantidade de interações seria 1.425, que é o total presente na tabela de tradução.

TRANSLATE_DRUG_INTERACTIONS:

Objetivo: Traduzir as interações medicamentosas da base original do DrugBank do inglês para o português usando a API do OpenAI (modelo GPT-3.5) e enriquecer a base HealDB com essas informações.

Processo:

1. Inserir as interações medicamentosas do DrugBank (`db_drug_interaction`) na tabela de tradução (`hd_priv_translate_port_drug_int`), cruzando com os princípios ativos existentes na base HealDB. (Função: `insert_table_translate_drug_int`)
2. Ao inserir na tabela de tradução, substituir os nomes das drogas associadas à interação por variáveis XXX e YYY para possibilitar posteriormente a substituição dessas variáveis pelos princípios ativos em português já existentes na base HealDB.
3. Traduzir o campo que contém as interações com a variável XXX e YYY (`ds_interaction_var`) usando a API do OpenAI (modelo GPT-3.5). Traduzir apenas as interações distintas, já que algumas se repetem devido ao uso das variáveis para os nomes das drogas, reduzindo assim o tempo necessário para tradução. O modelo GPT-3.5 foi o escolhido porque o GPT-4.0 estava muito lento e a qualidade da tradução foi similar. Armazenar a informação traduzida em uma coluna da tabela, ainda com as variáveis XXX e YYY (`ds_interaction_var_port`). (Funções: `perform_drug_interaction_translation` e `update_translate_drug_interaction`)
4. Substituir a variável XXX e YYY pelos princípios ativos em português da base HealDB e salvar na tabela final que compõe a base de medicamentos, na tabela `hd_drug_interaction`. (Funções: `replace_var_by_active_ingredient` e `insert_drug_interaction`). Devido à quantidade de registros das interações medicamentosas traduzidas, o insert foi realizado em lotes de 10.000 registros.

Resultado: A base HealDB será enriquecida com as interações medicamentosas:

- **A quantidade de interações resultantes foi 775.212.** Existem algumas interações repetidas, porque alguns princípios ativos são similares e se referem à mesma droga. Isso ocorre porque não foi feita a desambiguação dos princípios ativos, resultando em entradas duplicadas com descrições diferentes. No entanto, isso não compromete o resultado final da busca de interação a partir do MEDICAMENTO X PRINCÍPIO ATIVO.

Se a desambiguação fosse realizada, a quantidade de interações seria 461.554, que é o total presente na tabela de tradução.

TRANSLATE_DISEASE_DESCRIPTIONS:

Objetivo: Atualizar as descrições em inglês dos grupos, categorias e subcategorias da CID-10 na base HealDB, visando ampliar o suporte multilíngue e a interoperabilidade.

Processo:

1. Atualização com arquivos oficiais da OMS (WHO, 2008):
 - Leitura de arquivos .txt externos contendo as traduções oficiais das descrições da CID-10 em inglês.
 - Atualiza os campos:
 - `ds_group_eng` na tabela `hd_icd_group`
 - `ds_cat_eng` na tabela `hd_icd_category`
 - `ds_subcat_eng` na tabela `hd_icd_subcategory`
2. Tradução complementar com GPT (casos ausentes):
 - Para registros que não possuem tradução nos arquivos da OMS, o script utiliza o modelo GPT-4 para traduzir os campos restantes.
 - Campos traduzidos:
 - `ds_group` → `ds_group_eng`
 - `ds_cat` → `ds_cat_eng`
 - `ds_subcat` → `ds_subcat_eng` (utiliza a tradução da categoria como contexto quando disponível)
3. Configuração da API:
 - Os parâmetros da API do OpenAI (modelo, URL, headers) são lidos dinamicamente do módulo `config.py`.
4. Controle de desempenho e commits:
 - A cada 100 traduções realizadas com GPT, o script executa um `commit()` para preservar o progresso e evitar perdas em caso de erro.

4. Pasta: `c:\project\healdb\src\nlp_extraction`

EXTRACT_LEAFLET_SECTIONS:

Objetivo: Percorrer o repositório de bulas, ler as bulas, extrair o texto que corresponde à seção "Para que este medicamento é indicado?", "O que devo saber antes de usar esse medicamento?" e "Como este medicamento funciona?" de cada categoria de medicamento, e gravar o texto da indicação, da precaução e da funcionalidade no repositório de bulas.

Processo:

1. Ler a tabela de bulas `hd_medication_drug_leaflet` e armazenar em um `DataFrame`.

2. Iterar sobre cada registro do DataFrame que contém o conteúdo do repositório de bulas e armazenar o texto da indicação (vazio) no DataFrame `df_indication`, o texto da precaução(vazio) no DataFrame `df_precaution` e o texto da funcionalidade (vazio) no DataFrame `df_functionality`.
3. Para cada bula do DataFrame, extrair a indicação utilizando uma expressão regular para encontrar o início e fim da sessão “Para que este medicamento é indicado” (biblioteca `re` do python).
4. Para cada bula do DataFrame, extrair a precaução utilizando uma expressão regular para encontrar o início e fim da sessão “o que devo saber antes de usar esse medicamento” (biblioteca `re` do python).
5. Para cada bula do DataFrame, extrair a funcionalidade utilizando uma expressão regular para encontrar o início e fim da sessão “como este medicamento funciona” (biblioteca `re` do python).
6. Inserir os dataframes `df_indication`, `df_precaution` e `df_functionality` em uma tabela de trabalho: `hd_wrk_med_leaflet_section`.
7. Atualizar a tabela `hd_medication_drug_leaflet` com o texto da indicação, da precaução e da funcionalidade.

TRANSLATE_LEAFLET_INDICATION:

Objetivo: Traduzir o texto da seção "para que este medicamento é indicado" e "como este medicamento funciona" das bulas para o inglês. O intuito desta tradução é utilizar ferramentas em inglês que conseguem extrair sintomas e doenças de textos médicos.

Processo:

1. Copiar as indicações da tabela `hd_medication_drug_leaflet` para a tabela `hd_translate_eng_leaflet_section`.
2. Utilizar para a API da OpenAI do modelo GPT-3.5 para a tradução.
 - Durante a tradução houve muitas interrupções, e continuei de onde parei. Mas a partir do dia 13/06/2024 às 17h56 até 14/06/2024 às 13h11, o processo seguiu sem interrupção.
3. Houve problemas na tradução dos seguintes `id_medication`:
 - a) Atualizar como nula a tradução em inglês para esses IDs porque a origem (`ds_indication` da `hd_medication_drug_leaflet`) é nula: 671,1707, 1854, 1966, 2988, 3208, 3463, 3949, 4327, 4440, 4496, 5467, 5543, 5982, 5991, 6672, 7393, 9284, 9452, 9783.
 - b) Repetir a tradução para esses IDs: 614, 1208, 2176, 4024.
 - i. Para o ID 614 houve a necessidade de atualizar o `ds_indication` (em português) para remover um caracter especial que prejudicou a tradução.
 - ii. Para os demais IDs, a tradução foi submetida novamente e o resultado foi satisfatório.
4. A tradução da seção “como este medicamento funciona” ocorreu em 29/05/2025. Essa seção foi incorporada para enriquecer os dados que são enviados para a API da Amazon Comprehend Medical, dando mais contexto para a extração das doenças.

EXTRACT_DISEASES_FROM_INDICATIONS:

Objetivo: Ler as indicações das bulas traduzidas para o inglês e utilizar o modelo pré-treinado Amazon Comprehend Medical para extrair as doenças/sintomas como códigos ICD-10-CM, armazenando a evidência (texto submetido) e a resposta bruta da API em JSON.

Processo:

1. Para usar os serviços da Amazon Web Services (AWS), é necessário importar a biblioteca Boto3 que é uma biblioteca de cliente para Python. O Boto3 fornece uma interface para interagir com os diversos serviços da AWS. Com essa biblioteca, é possível utilizar APIs, como a que realiza a extração de códigos CID a partir de textos médicos.
2. Ler a tabela `hd_translate_eng_leaflet_section`.
3. Para cada registro:
 - a) Aplicar pré-processamento no texto de indicação (`ds_indication_eng`), incluindo:
 - i) Substituição do nome do medicamento por `<drug>` (case-insensitive) para reduzir variações/ruído no texto.
 - ii) Normalização da expressão “with or without” para “regardless of”.
 - b) Montar o texto final enviado ao modelo com um cabeçalho (“What this medication is indicated for: ...”).
 - c) Limitar o texto a 10.000 caracteres (limite prático para submissão).
 - d) Chamar a API do Comprehend Medical `comprehend_client_infer_icd10_acm` para inferência de ICD-10-CM, passando `Text=full_text`.
4. Converter a resposta da API para JSON e persistir na tabela `hd_int_med_disease_api_response`:
 - `id_medication`
 - `ds_text_submitted` (texto enviado)
 - `ds_api_response` (JSON com a resposta)
 - Usar `INSERT ... ON DUPLICATE KEY UPDATE` para permitir reprocessamento.
5. Realizar commits em lote (para reduzir custo de transação) e ao final do processamento.

PROCESS_DISEASE_DATA_JSON:

Objetivo: Processar o JSON retornado pelo Amazon Comprehend Medical (armazenado em `hd_int_med_disease_api_response.ds_api_response`) e materializar todos os candidatos extraídos (entidades, conceitos ICD-10-CM e traits) em tabelas relacionais para auditoria e aplicação de regras de corte posteriores.

Processo:

1. (Opcional) Truncar as tabelas de saída antes de carregar:
 - `hd_int_med_disease_entity_icd`
 - `hd_int_med_disease_entity_trait`
2. Ler `id_medication` e `ds_api_response` da tabela `hd_int_med_disease_api_response` (apenas onde `ds_api_response` não é nulo).
3. Para cada medicamento:
 - a) Converter o JSON (string) em dicionário.

b) Iterar sobre a lista Entities.

c) Para cada entidade (ocorrência no texto), extrair e persistir os metadados essenciais, incluindo:

- `nr_entity_id` (ID da entidade retornado pela API; se ausente, usar um fallback incremental)
 - `ds_entity_text` (termo detectado no texto)
 - `tp_entity` (tipo, ex.: `DX_NAME`)
 - `ds_category` (categoria)
 - `vl_entity_score` (score/confiança da entidade)
 - `nr_begin_offset` e `nr_end_offset` (posição no texto)
 - `ds_attributes` (lista de atributos serializada em JSON)
4. Persistir concepts ICD-10-CM sugeridos para cada entidade em `hd_int_med_disease_entity_icd` (uma linha por entidade × ICD):
- `id_medication`
 - `nr_entity_id`
 - (metadados da entidade)
 - `cd_icd_full` (código ICD-10-CM)
 - `ds_icd` (descrição)
 - `vl_icd_score` (score do conceito ICD sugerido)
 - Usar `ON DUPLICATE KEY UPDATE` para reexecução.
5. Persistir traits de cada entidade em `hd_int_med_disease_entity_trait` (uma linha por entidade × trait):
- `id_medication`
 - `nr_entity_id`
 - `nm_trait`
 - `vl_trait_score`
6. Executar inserts em batch (tamanho configurável) com commits periódicos para ter mais eficiência.

LINK_MEDICATIONS_WITH_DISEASES:

Objetivo: Aplicar a política de corte sobre os candidatos do Comprehend Medical (ICD-10-CM + evidências) e gerar associações finais **medicamento–doenças (CID)** no HealDB, mantendo também uma tabela de auditoria detalhada para rastreabilidade e validação científica.

Processo:

1. Definir parâmetros de corte (via variáveis de sessão no banco):
 - `entity_score_min` (padrão: 0,70) — score mínimo da entidade.
 - `icd_medium_min` (padrão: 0,30) — limite mínimo para classificar ICD como MEDIUM.
 - `icd_high_min` (padrão: 0,60) — limite mínimo para classificar ICD como HIGH.
2. (Opcional) Truncar as tabelas de saída antes de executar:
 - `hd_int_med_disease_cutoff_audit` (auditoria)
 - `hd_medication_disease` (resultado final)

3. Construir e carregar a tabela de auditoria `hd_int_med_disease_cutoff_audit` (1 linha por entidade), aplicando:
 - a) Seleção do top-1 ICD-10-CM por entidade (maior `vl_icd_score`, com desempate por código).
 - b) Identificação de `NEGATION` (flag binária) com base nos traits registrados.
 - c) Identificação do trait principal (maior `vl_trait_score`) apenas para fins de documentação/auditoria.
 - d) Mapeamento de ICD-10-CM → repositório ICD-10 do HealDB:
 - Remover o ponto do código (`REPLACE(cd_icd_full, '.', '')`).
 - Tentar match exato com `hd_icd_subcategory.cd_subcat`.
 - Se não existir subcategoria, aplicar fallback pela categoria de 3 caracteres (prefixo) em `hd_icd_category.cd_cat`.
 - Registrar o tipo de mapeamento (`SUBCAT_EXACT`, `CAT3_FALLBACK` ou `NO_MAP`) e os IDs correspondentes (`id_icd_group`, `id_icd_cat`, `id_icd_subcat`).
 - e) Calcular flags de aprovação (pass/fail) para os pré-filtros:
 - Manter apenas entidades do tipo `DX_NAME`.
 - Excluir entidades com `NEGATION`.
 - Exigir `vl_entity_score ≥ entity_score_min`.
4. Carregar a tabela final `hd_medication_disease`, a partir da tabela de auditoria `hd_int_med_disease_cutoff_audit`:
 - a) Selecionar apenas registros elegíveis que passaram nos pré-filtros e possuem mapeamento ICD válido.
 - b) **Deduplicar** por (`id_medication`, `cd_icd_final`) mantendo a melhor evidência (maior score ICD; desempate por maior entity score).
 - c) Classificar o score do ICD em `LOW`, `MEDIUM` ou `HIGH`.
 - d) Inserir apenas associações finais com `tp_icd_score MEDIUM and HIGH`.
5. Ao final, a tabela `hd_medication_disease` contém:
 - a) Código ICD final (já mapeado para o padrão do HealDB),
 - b) IDs (grupo/categoria/subcategoria),
 - c) Scores consolidados (entidade e ICD),
 - d) Trait principal e seu score (para suporte de análise).

5. Pasta: `c:\project\healdb\src\interoperability\linking`

Scripts para integração de dados de fontes externas por meio de external ids.

IMPORT_DCB_DATA:

Objetivo: Importar e processar os dados das Denominações Comuns Brasileiras (DCB) para o HealDB.

Processo:

1. Carregar os dados das DCB de um arquivo Excel.

2. Mapear e inserir classificações e descrições no banco de dados na tabela `hd_dcb_classification`.
3. Preencher a tabela `hd_dcb_list` com informações como números DCB, nomes, números CAS e histórico de classificação.

POPULATE_EXTERNAL_IDS_TYPES:

Objetivo: Popular a tabela `hd_type_ext_id` com os diferentes tipos de identificadores externos utilizados por diversas bases de dados na área da saúde.

Processo:

1. O script verifica se a tabela `hd_type_ext_id` já contém registros.
2. Caso a tabela esteja vazia, ele inicia a etapa de inserção.
3. São carregados os seguintes identificadores externos, cada um com uma descrição curta e uma explicação mais detalhada:
 7. CAS: CAS Number – Identificador numérico único atribuído pelo Chemical Abstracts Service.
 8. RXCUI: RxNorm CUI – Identificador único de conceito do RxNorm para nomes normalizados de medicamentos.
 9. PUBCHEM_CID: PubChem Compound ID – Identificador de compostos químicos no banco PubChem Compound.
 10. KEGG_DRUG: KEGG Drug ID – Identificador de medicamentos no banco de dados KEGG Drug.
 11. KEGG_COMP: KEGG Compound ID – Identificador de compostos químicos no KEGG Compound.
 12. DRUGBANK_ID: DrugBank ID – Identificador exclusivo de medicamentos na base DrugBank.
 13. SNOMEDCT: SNOMED CT – Identificador de conceitos médicos nos termos clínicos do SNOMED.
 14. CHEBI: ChEBI ID – Identificador de entidades químicas na base ChEBI.
 15. ATC: ATC Code – Código da Classificação Anatômica Terapêutica Química.
 16. UNII_CODE: UNII Code – Identificador único de ingrediente (Unique Ingredient Identifier) da FDA.
4. Cada identificador é inserido na tabela `hd_type_ext_id` com os campos:
 - `tp_ext_id`: Código do tipo de identificador externo.
 - `ds_short_type`: Descrição curta.
 - `ds_long_type`: Descrição longa.

EXTERNAL_IDS_INSERT:

Objetivo: Inserir os IDs Externos nas tabelas do HealDB. É uma função chamada nos diversos scripts que efetuam a ligação entre external ids e o princípio ativo do HealDB, evitando repetição de código e centralizando em uma única função.

Descrição do processo:

1. Antes de inserir, valida se o tipo do “external id” existe na tabela `hd_type_ext_id`.
2. Se não existir, interrompe o processo. Caso contrário, continua.
3. Insere o “external id” na tabela `hd_active_ingredient_ext_id`, apenas se ainda não existir esse código e tipo associado ao princípio ativo.

LINK_CAS_TO_ACTIVE_ING:

Objetivo: Associar os princípios ativos aos respectivos CAS Numbers da lista DCB, permitindo a interoperabilidade com bases e ontologias biomédicas externas.

Descrição do processo:

1. A tabela `hd_active_ingredient_ext_id` é limpa (TRUNCATE) para evitar duplicações.
2. A função `link_cas_from_dcb_to_active_ing_ext_id` vincula os CAS Numbers da tabela `hd_dcb_list` aos princípios ativos da `hd_active_ingredient`, com base na correspondência dos nomes.
3. São inseridos apenas CAS válidos (não nulos, sem [Ref...]), e ainda não vinculados.
4. Cada vínculo registra o tipo (CAS) e a origem (DCB).

LINK_DRUGBANK_TO_ACTIVE_ING:

Objetivo: Registrar os DrugBank IDs de princípios ativos no HealDB, persistindo-os na tabela `hd_active_ingredient_ext_id`. Este processo **não faz a harmonização** (tradução/matching); ele apenas materializa os identificadores obtidos previamente.

Descrição do processo:

1. Remover registros anteriores de DrugBank para permitir reexecução limpa:
 - `DELETE FROM hd_active_ingredient_ext_id WHERE tp_ext_id = 'DRUGBANK_ID'`
2. Inserir novamente os DrugBank IDs na tabela `hd_active_ingredient_ext_id` a partir do mapeamento já existente:
 - Ler a tabela de mapeamento `hd_priv_active_ingredient_drug` (relaciona `id_active_ingredient` com entradas do DrugBank).
 - Fazer join com a tabela `db_drug` para obter `id_drugbank`.
 - Inserir:
 - `id_active_ingredient`
 - `tp_ext_id = 'DRUGBANK_ID'`
 - `cd_ext_id = id_drugbank`
 - `fl_origin_ext_id = 'DRUGBANK'`
3. Evitar duplicidades usando verificação `NOT EXISTS` para o mesmo (`id_active_ingredient`, `tp_ext_id`)

LINK_RXCUI_TO_ACTIVE_ING:

Objetivo: Vincular os identificadores únicos de conceito do RxNorm (RXCUI) aos princípios ativos armazenados no HealDB, permitindo buscas e interoperabilidade com outras fontes e ontologias biomédicas.

Processo:

1. Ler os princípios ativos da tabela `hd_translate_eng_active_ing`, considerando apenas os que já possuem tradução final para o inglês.
2. Consultar a API do RxNorm utilizando o nome do princípio ativo em inglês para recuperar o identificador RXCUI correspondente.
3. Armazenar o identificador externo na tabela de interoperabilidade utilizando o tipo RXCUI e a origem RXNORM.
4. Registrar os dados na tabela `hd_active_ingredient_ext_id`, conectando o `id_active_ingredient` ao `cd_ext_id` (RXCUI).

LINK_RXCUI_RELATED_IDS_TO_ACTIVE_ING:

Objetivo: Vincular ao HealDB os identificadores externos relacionados ao RxNorm, como SNOMED CT, ATC, UNII e DrugBank, utilizando o identificador RxCUI previamente associado aos princípios ativos. Isso permite enriquecer a interoperabilidade com outras bases biomédicas e ontologias de saúde.

Processo:

1. Ler os princípios ativos da tabela `hd_active_ingredient_ext_id` que já possuem o identificador externo do tipo RXCUI.
2. Consultar a API do RxNorm para cada RxCUI, solicitando os seguintes identificadores relacionados: SNOMEDCT, ATC, UNII_CODE e DRUGBANK.
3. Para cada identificador externo encontrado, inserir na tabela `hd_active_ingredient_ext_id`, associando o `id_active_ingredient` ao valor retornado (`cd_ext_id`) com o respectivo tipo (`tp_ext_id`) e origem RXNORM.
4. Realizar chamadas com pequenos *delays* para respeitar os limites da API e evitar bloqueios.

LINK_WIKIDATA_IDS_TO_WRK_TABLE:

Objetivo: Buscar identificadores externos de fontes biomédicas no Wikidata utilizando os códigos RXCUI como entrada, armazenando os resultados em uma tabela de trabalho para posterior integração ao HealDB. Essa etapa visa enriquecer a base com links para ontologias como PubChem, ChEBI, KEGG, SNOMED CT e DrugBank.

Processo:

1. Buscar os princípios ativos do HealDB que já possuem o identificador externo do tipo RXCUI.
2. Agrupar os `rx cui` em lotes de 100 e consultar a API SPARQL do Wikidata para obter os identificadores externos relacionados.
3. Extrair os seguintes identificadores (quando disponíveis): CAS, DrugBank, PubChem, ChEBI, SNOMED CT, ATC, UNII, KEGG Compound e KEGG Drug.
4. Armazenar os resultados na tabela de estágio `hd_wrk_wikidata_ext_id`, garantindo que cada registro esteja vinculado ao `rx cui` correspondente e à URL do item no Wikidata (`ds_url_wikidata`).
5. Verificar os tipos válidos de identificadores externos com base na tabela `hd_type_ext_id` antes de inserir.
6. Utilizar `executemany` para inserir os dados em lote, evitando duplicações e otimizando o desempenho.
7. Adicionar um pequeno *delay* entre os lotes para evitar bloqueio por excesso de requisições na API do Wikidata.

LINK_KEGG_RELATED_IDS_TO_ACTIVE_ING:

Objetivo: Conectar identificadores externos relacionados (PubChem CID e ChEBI ID) aos princípios ativos do HealDB, utilizando o identificador do KEGG (Compound) previamente obtido via Wikidata. Essa integração permite ampliar a interoperabilidade com outras fontes biomédicas abertas.

Processo:

1. Buscar os identificadores KEGG_COMP presentes na tabela `hd_wrk_wikidata_ext_id`, associados a princípios ativos do HealDB com RXCUI registrado.
2. Remover da tabela `hd_active_ingredient_ext_id` todos os registros com origem KEGG ou cujo tipo de identificador externo (`tp_ext_id`) comece com KEGG.
3. Para cada identificador KEGG_COMP obtido, consultar a API pública do KEGG para recuperar os identificadores externos relacionados (PubChem CIDs e ChEBI ID).
4. Regravar o KEGG_COMP na tabela `hd_active_ingredient_ext_id` com origem WIKIDATA, e inserir os identificadores PubChem e ChEBI obtidos com origem KEGG.
5. Repetir o processo para todos os KEGG_COMP vinculados a princípios ativos, garantindo a vinculação completa entre os identificadores.

FILL_MISSING_EXTERNAL_IDS:

Objetivo: Preencher os identificadores externos ausentes na tabela `hd_active_ingredient_ext_id`, utilizando os dados previamente carregados na tabela de trabalho `hd_wrk_wikidata_ext_id`, com base em correspondência pelo código RXCUI.

Processo:

1. Identificar os princípios ativos que possuem RXCUI e estão presentes em `hd_wrk_wikidata_ext_id`.
2. Verificar se já possuem o identificador externo correspondente cadastrado.

3. Inserir os novos identificadores externos que ainda não estão registrados do tipo CAS, ATC, SNOMEDCT, UNII_CODE, CHEBI and PUBCHEM CID.
4. Registrar a origem como WIKIDATA.

6. Pasta: c:\project\healdb\src\interoperability\usecases

Scripts ou queries sparql para demonstrar os casos de uso de interoperabilidade do HealDB, explorando as conexões possíveis entre os princípios ativos do banco de dados e fontes externas de informação em saúde. Cada caso de uso mostra, de forma prática, como integrar o HealDB a bases abertas como ChEBI, PubChem, IUCN, ATC, RxNorm entre outras, utilizando SPARQL ou APIs. Os resultados enriquecem os princípios ativos com atributos químicos, status de conservação, publicações científicas, estudos clínicos e outros dados biomédicos relevantes.

ATC_ATTRIBUTES_QUERY e ATC_ATTRIBUTES_THERAPHEALDB

Objetivo:

Demonstrar a interoperabilidade semântica entre o HealDB e a ontologia ATC por meio de duas queries SPARQL executadas no Apache Jena Fuseki. As queries cruzam dados de dois grafos RDF dentro do dataset healdb_full:

- Grafo <<http://healdb.org/graph/healdb>>: contém os princípios ativos do HealDB, seus identificadores externos, medicamentos, classes terapêuticas e categorias regulatórias. (healdb_mini.ttl)
- Grafo <<http://healdb.org/graph/atc>>: contém a ontologia ATC, incluindo classes terapêuticas e identificadores UMLS. (atc.owl)

Atributos retornados na Query 1:

- `idActiveIngredient`: Identificador do princípio ativo no HealDB.
- `nameActiveIngredient`: Nome do princípio ativo.
- `atcCode`: Código ATC associado ao princípio ativo.
- `umlsCUI`: Identificador CUI (Concept Unique Identifier) do UMLS que representa um conceito médico padronizado.
- `umlsTUI`: Identificador TUI (Type Unique Identifier) do UMLS que define o tipo ou a categoria do conceito no UMLS.
- `therapeuticClass`: Classe terapêutica no ATC.
- `prefLabel`: Nome preferido da classe terapêutica no ATC.
- `altLabel`: Nome alternativo da classe terapêutica no ATC.

Atributos retornados na Query 2:

Os mesmos atributos da Query 1, além de:

- `healdbClassTherapeutics`: Classe terapêutica associada ao medicamento no HealDB, permitindo a comparação entre a classe no nível do medicamento e no nível do princípio ativo.

Aplicação no HealDB:

- A primeira query retorna a classificação terapêutica dos princípios ativos segundo o ATC, incluindo identificadores UMLS e termos preferidos/alternativos, fornecendo uma base para padronização semântica.
- A segunda query estende a primeira ao incluir as classes terapêuticas associadas aos medicamentos em HealDB, possibilitando a análise comparativa entre as classificações atribuídas no ATC e as registradas em HealDB.
- Essas queries são essenciais para identificar possíveis discrepâncias entre a classificação terapêutica no nível do princípio ativo e no nível do medicamento, além de possibilitar a análise de múltiplas classes terapêuticas compartilhadas por um mesmo princípio ativo.

Saídas:

- `atc_attributes_healdb.csv`: Mapeamento das classes terapêuticas ATC associadas aos princípios ativos do HealDB.
- `atc_attributes_theraphealdb.csv`: Mapeamento das classes terapêuticas ATC para os princípios ativos do HealDB, incluindo a classe terapêutica associada aos medicamentos que contêm esses princípios ativos.

CHEBI_ATTRIBUTES_QUERY:

Objetivo: Demonstrar a interoperabilidade semântica entre o HealDB e a ontologia ChEBI por meio de uma query SPARQL executada no Apache Jena Fuseki. O caso de uso não corresponde a um script, mas sim a uma consulta SPARQL que cruza dois grafos RDF dentro do dataset `healdb_full`:

- Grafo `<http://healdb.org/graph/healdb>`: contém os princípios ativos do HealDB e seus identificadores externos.
- Grafo `<http://healdb.org/graph/chebi>`: contém a ontologia completa da ChEBI (arquivo `chebi.owl`).

Atributos retornados:

- `ingredientLabel`: nome do princípio ativo
- `externalId`: identificador externo (ChEBI ID)
- `chebiEntity`: URI do composto na ontologia ChEBI
- `formula`: fórmula molecular
- `mass`: massa molecular média
- `monoisotopicMass`: massa mono-isotópica
- `smiles`: notação estrutural SMILES
- `inchi`: identificador InChI
- `inchikey`: identificador InChIKey

Saídas:

- `chebi_attributes_healdb.csv`: Atributos químicos dos princípios ativos do HealDB, incluindo fórmula molecular, massa, massa monoisotópica e identificadores (SMILES, InChI e InChIKey).
- `chebi_attributes_healdb_json.json`: Os mesmos atributos em formato JSON.

CLINICAL_TRIALS_EXPORT:

Objetivo: Consultar dados de estudos clínicos relacionados a princípios ativos registrados na base HealDB por meio da API v2 do ClinicalTrials.gov. O objetivo é identificar estudos clínicos em andamento ou concluídos que envolvem esses princípios ativos, capturando informações sobre condições clínicas, intervenções testadas e resultados reportados.

Processo:

1. Recuperar os princípios ativos e seus nomes em inglês na tabela `hd_translate_eng_active_ing`, associando-os a cada `id_active_ingredient`.
2. Consultar a API do ClinicalTrials.gov para cada princípio ativo, capturando: NCT ID – identificador único do estudo clínico; Título – título breve do estudo clínico; Condições – Condições clínicas abordadas no estudo; Intervenções – intervenções testadas no estudo, incluindo o princípio ativo; Resultados – Resultados reportados para as intervenções.
3. Inserir os dados na tabela de trabalho `hd_wrk_clinical_trials`, garantindo que não haja duplicidade de registros com base no `id_active_ingredient` e `cd_nct`.
4. Exportar os resultados para dois arquivos, um em formato CSV e outro em formato JSON com estrutura aninhada, organizando os estudos clínicos por princípio ativo.
5. A consulta retorna **todos os estudos clínicos disponíveis** para cada nome científico, incluindo os campos listados acima.
6. Armazenar os resultados em dois arquivos JSON, com resumos informando totais processados e com dados válidos.

Saídas:

- `clinical_trials_healdb.csv`: Arquivo CSV com dados sobre estudos clínicos para os princípios ativos do HealDB, incluindo ID, nome do princípio ativo, NCT ID, título do estudo, condições, intervenções e resultados reportados.
- `clinical_trials_healdb.json`: Estrutura JSON com a mesma estrutura do CSV, organizada por princípio ativo e incluindo os estudos clínicos relacionados.

OBS: A documentação da API ClinicalTrials.gov v2 pode ser consultada em:

<https://clinicaltrials.gov/api/v2/studies>.

IUCN_EXPORT_CONSERVATION_STATUS:

Objetivo: Consultar o status de conservação, ameaças e distribuição geográfica de nomes relacionados a plantas medicinais (classificação DCB = "PM") por meio da API V4 da IUCN (International Union for Conservation of Nature), considerando tanto os nomes da lista DCB quanto os princípios ativos já registrados na base HealDB.

Processo:

1. Recuperar os nomes da Denominação Comum Brasileira (DCB) classificados como "PM", independentemente de estarem ou não associados a um princípio ativo na base.
2. Recuperar os princípios ativos da base `Healdb` que estejam vinculados a DCBs classificados como "PM".
3. Normalizar os nomes científicos, removendo sufixos como nomes de autores e espaços invisíveis, mantendo apenas o gênero e espécie (ex: "*Aesculus hippocastanum*").
4. Consultar a API da IUCN para obter:
 - Status de conservação (ex: "Vulnerável", "Em perigo") - capturado dos campos "category" e "category_description".
 - Ano de avaliação e escopo geográfico do assessment (ex: Global, Europe, Mediterranean, Pan-Africa) - capturados dos campos "year_published" e "scopes".
 - Informações sobre possível extinção - capturadas dos campos "possibly_extinct" e "possibly_extinct_in_the_wild".
 - Principais ameaças - capturadas do campo "threats" como uma lista.
 - Localizações geográficas - capturadas do campo "locations" como uma lista.

A consulta retorna **todos os assessments disponíveis** para cada nome científico, incluindo os campos listados acima.

5. Armazenar os resultados em arquivos JSON, com resumos informando totais processados e com dados válidos.

Saídas:

- `iucn_conservation_healdb.json`: Dados de conservação para os princípios ativos da base HealDB vinculados a DCBs do tipo "PM".
- `iucn_conservation_dcb.json`: Dados de conservação para **todos** os nomes DCB classificados como "PM", mesmo que não estejam associados a um princípio ativo.

OBS: A documentação da API está disponível no Swagger neste link:

<https://api.iucnredlist.org/api-docs/index.html>, onde é possível simular a execução dos endpoints e visualizar seus retornos.

PUBCHEM_EXPORT_REFERENCES:

Objetivo: Obter publicações científicas relacionadas a princípios ativos classificados como "antidepressivos" no HealDB, utilizando o identificador PubChem CID como chave de ligação com a base PubMed. A coleta é feita via APIs públicas da NCBI (Entrez E-Utilities), enriquecendo a base HealDB com referências científicas associadas a cada composto químico.

Processo:

1. Executar a consulta SQL na base HealDB para selecionar os princípios ativos associados à classe terapêutica "antidepressivo" que possuem identificador externo do tipo `PUBCHEM_CID`.
2. Para cada PubChem CID, consultar o endpoint `elink.fcgi` (Entrez API) para recuperar os PMIDs (identificadores de publicações no PubMed) relacionados.

3. Para cada PMID recuperado, obter os seguintes detalhes das publicações:
 - `title`: título da publicação
 - `journal`: periódico
 - `date`: data de publicação
4. Selecionar e ordenar as publicações por ano e mês (de forma aproximada) e manter as **três mais recentes**, com base na data retornada pela API (`PubDate`)..
5. Exportar o resultado em JSON, gravando o resultado no arquivo `pubchem_reference_healdb.json`, com os campos:
 - `id_active_ingredient`
 - `nm_active_ingredient`
 - `cd_pubchem_cid`
 - `publications`: lista de até três objetos contendo `pmid`, `title`, `journal`, `date`.

Saída:

- `pubchem_reference_healdb.json`: Até três publicações científicas do PubMed associadas aos princípios ativos do HealDB.

RXNORM_EXPORT_ENRICHED_INGREDIENTS:

Objetivo:

Enriquecer os princípios ativos da base HealDB com informações clínicas e farmacológicas provenientes da API pública do RxNorm, utilizando o identificador RxCUI (RxNorm Concept Unique Identifier) previamente conectado à base. O enriquecimento inclui nome preferido, tipo de conceito, status detalhado, sinônimos e apresentações clínicas e comerciais, possibilitando análises mais completas e integração com outras ontologias biomédicas.

Processo:

1. Selecionar todos os princípios ativos que possuem identificador externo do tipo "RXCUI", conforme armazenado na tabela `hd_active_ingredient_ext_id`.
2. Para cada princípio ativo com RxCUI, consultar a API pública do RxNorm para recuperar:
 - Nome preferido (`preferred name`)
 - Tipo de termo (TTY), como IN (Ingredient) ou PIN (Precise Ingredient)
 - Status detalhado, incluindo:
 - `status`: Situação conceitual (e.g., Active, Obsolete, NotCurrent, Remapped)
 - `current`: Se o conceito ainda está ativo na base RxNorm
 - `release_start_date`: Primeiro release mensal do RxNorm em que o conceito apareceu
 - `release_end_date`: Último release em que o conceito foi incluído (vazio se ainda ativo)
3. Recuperar os sinônimos associados ao RxCUI utilizando o endpoint de propriedades da API.
4. Consultar apresentações clínicas utilizando o TTY "SCD" (Semantic Clinical Drug), que representam combinações específicas de princípio ativo, dose e forma farmacêutica.

5. Consultar apresentações comerciais utilizando os TTYs "SBD", "BPCK", "SBDF" e "SBDC", por meio de chamadas separadas à API (uma para cada TTY).
6. Estruturar os dados enriquecidos em dicionários Python contendo todos os campos relevantes para cada princípio ativo.
7. Armazenar o resultado final em um arquivo JSON com todos os princípios ativos enriquecidos.

Saída:

- `rxnorm_enrichment_healdb.json`: Arquivo JSON contendo os dados enriquecidos para os princípios ativos com RxCUI, incluindo nome, status detalhado e dados de vigência no RxNorm, sinônimos, apresentações clínicas e apresentações comerciais.

7. Pasta: `c:\project\healdb\src\interoperability\usecases\_attempts`

Alguns casos de uso foram implementados de forma exploratória, mas não foram incorporados definitivamente ao HealDB. Apesar disso, foram documentados e seus resultados permanecem salvos na pasta `_attempts` para futura referência ou reavaliação.

PUBCHEM_DISEASE_QUERY, PUBCHEM_MESH_DISEASE_QUERY e PUBCHEM_MESH_IDS_QUERY (Coocorrências de Doenças)

Objetivo:

Explorar a associação entre princípios ativos do HealDB e doenças mencionadas em publicações científicas por meio de coocorrência com identificadores MeSH, utilizando dados RDF do PubChem e consultas SPARQL.

Processo:

1. Os dados RDF do PubChem foram carregados no Fuseki.
2. Consultas SPARQL associaram PubChem CIDs → DZIDs → MeSH IDs.
3. A API do MeSH seria usada para enriquecer os dados de doenças.

Saídas:

- `pubchem_mesh_disease_healdb.csv`; `pubchem_mesh_ids_healdb.csv`; - `pubchem_diseases_labels.csv`: arquivos que seriam utilizados como input para o script em python que chamaria a API do Mesh para trazer detalhes sobre as doenças associadas ao princípio ativo.

Motivo do descarte: As coocorrências extraídas não refletem relações terapêuticas entre os princípios ativos e as doenças, gerando associações vagas e imprecisas. A integração foi substituída pelo uso da base ClinicalTrials.gov.

IUCN_EXPORT_CONSERVATION_STATUS_R:

Objetivo: Recuperar status de conservação e ameaças para princípios ativos de identificados como plantas medicinais utilizando a API da IUCN Red List v4 via R.

Processo:

1. Foram consultados nomes científicos de DCBs classificados como "PM" (plantas medicinais).
2. Os resultados incluíram categoria de ameaça, risco de extinção, escopo geográfico e principais ameaças.
3. A versão em R foi desenvolvida devido a problemas temporários de autenticação na versão em Python.

Saídas:

- `iucn_conservation_healdb_r.json`; `iucn_conservation_dcb_r.json`: arquivos que contém os dados de conservação dos princípios ativos e da lista DCB identificados como Plantas Medicinais (PM).

Motivo da migração: Após resolver os problemas de autenticação, a versão final em Python foi priorizada por integrar melhor ao projeto, visto que toda a pipeline está desenvolvida em Python.

8. Pasta: `c:\project\healdb\src\rdf_schema`

CREATE_HEALDB_RDF_SCHEMA**Objetivo:**

Gerar o RDF Schema completo do HealDB (sem instâncias) com base nas definições DDL do banco de dados relacional. O objetivo é representar estruturalmente todas as tabelas e suas relações (chaves estrangeiras) no formato RDF utilizando a biblioteca `rdflib`.

Processo:

1. Ler os arquivos DDL (`.sql`) a partir do diretório `PATHS["healdb_ddls"]`.
2. Extrair a estrutura do RDF Schema:
 - As colunas são identificadas como propriedades do tipo `owl:DatatypeProperty`, com inferência de tipo XSD (`string`, `integer`, `date`).
 - As chaves estrangeiras são representadas como `owl:ObjectProperty`, conectando classes distintas.
3. Criar as classes OWL:
 - Cada tabela é convertida em uma `owl:Class`, com rótulo (`rdfs:label`) correspondente ao nome.
4. Salvar o RDF Schema do HealDB no arquivo `healdb_complete.ttl`, localizado em `PATHS["output_rdf_schema"]`.

Saída:

- `healdb_complete.ttl`: Arquivo Turtle contendo o RDF Schema completo do banco de dados HealDB, sem dados instanciados.

CREATE_MINI_HEALDB_RDF_SCHEMA

Objetivo:

Gerar um RDF Schema instanciado do HealDB contendo as principais entidades e relacionamentos focados em princípios ativos (`ActiveIngredient`), identificadores externos (`ExternalIdentifier`), tipos de identificadores (`IdentifierType`), medicamentos (`Medication`), classe terapêutica (`TherapeuticClass`) e categoria regulatória (`RegulatoryCategory`). O RDF inclui instâncias reais extraídas do banco de dados MySQL.

Processo:

1. Definir as Classes e Propriedades:
 - São criadas as classes `ActiveIngredient`, `ExternalIdentifier`, `IdentifierType`, `Medication`, `TherapeuticClass`, and `RegulatoryCategory`.
 - São definidas as propriedades do tipo `owl:ObjectProperty` e `owl:DatatypeProperty` com seus domínios e ranges.
2. Ler os dados do banco MySQL e instanciar o schema:
 - São lidas as tabelas `hd_active_ingredient`, `hd_active_ingredient_ext_id`, `hd_type_ext_id`, `hd_medication`, `hd_medication_active_ingredient`, `hd_therapeutic_class`, and `hd_regulatory_category`.
 - Para cada entidade, são criadas instâncias com base nos dados extraídos, vinculando princípios ativos a identificadores externos, classes terapêuticas, categorias regulatórias e medicamentos.
3. Adicionar relações `owl:sameAs` para os identificadores externos do tipo CHEBI e ATC.
4. Estabelecer relações entre princípios ativos e classes terapêuticas com base nos medicamentos associados.
5. Salvar o RDF Schema simplificado do HealDB no arquivo `healdb_mini.ttl`, localizado em `PATHS["output_rdf_schema"]`.

Saída:

- `healdb_mini.ttl`: Arquivo Turtle contendo o schema RDF simplificado do HealDB com dados instanciados, focado na interoperabilidade semântica com outras ontologias (ex.: ChEBI, ATC).

9. Pasta: c:\project\healdb\src\webcrawler

Objetivo: Notebook interativo para análise exploratória dos dados do HealDB.

Fornece uma visão geral da estrutura e do conteúdo do banco por meio de visualizações e perguntas-chave.

- **Principais Funcionalidades:**
 - Apresenta resumos visuais (ex.: gráficos de barras, setores e dispersão) utilizando `matplotlib`, `pandas` e `seaborn`, com base nos dados do HealDB.
 - Responde a perguntas analíticas sobre medicamentos, princípios ativos e doenças.
 - Auxilia na verificação das relações entre medicamentos, doenças e interações.
 - Resume os principais achados resultantes das análises.

Perguntas-chave:

- Quais são as principais classes terapêuticas desses medicamentos?
- Existe predominância de alguma categoria regulatória (ex: Genérico, Similar) entre os medicamentos?
- Quais são os medicamentos mais próximos da expiração?
- Quais as empresas que mais fornecem medicamentos?
- Quais são os TOP 10 princípios ativos mais utilizados?
- Quais são os princípios ativos que estão presentes no maior número de medicamentos, em ordem decrescente de ocorrência?
- Quais medicamentos existentes contêm um determinado princípio ativo?
- Quais doenças têm mais medicamentos associados? TOP 15
- Quais medicamentos são mais versáteis (tratam mais doenças)?
- Quais princípios ativos são mais versáteis (tratam mais doenças)?
- Quais são os scores médios por categoria CID?
- Para uma doença específica, quais são os medicamentos associados e seus scores?
- Qual a distribuição do score de associação entre o medicamento e a doença?
- Existem interações medicamentosas entre dois princípios ativos específicos? Quais são elas?
- Quais as interações medicamentosas de um determinado medicamento?
- Um determinado medicamento possui interações com alimentos?
- Quais são os TOP 20 princípios ativos que apresentam o maior número de interações medicamentosas, em ordem decrescente de frequência?